

Predição de Risco de Crédito – aprovação cartão de crédito

Desenvolvimento de modelo de Machine Learning para prever a aprovação de pedidos de cartão de crédito com base no perfil dos solicitantes.

Ellen de Almeida Araújo
RM 377818
Turma 2DTATBB

1. Problema de negócio

Classificar clientes como bons ou maus pagadores para apoiar a concessão de crédito, equilibrando Oportunidade e Risco

Oportunidade

Ampliar a capacidade de concessão para clientes com potencial, usando evidências históricas.

Risco

Decisões inadequadas podem elevar inadimplência, perdas financeiras e custos de recuperação.

Desafio

Identificar antecipadamente solicitantes com maior probabilidade de comportamento de risco.

O projeto utiliza classificação supervisionada para transformar dados cadastrais, financeiros e históricos em uma classificação de risco.

2. Transformando comportamento em regra de negócio

Antes do algoritmo, foi necessário definir o que significa “maior risco”

Regra 1 — Recorrência grave

STATUS ≥ 2 (60 dias ou mais de atraso)
em mais de 50% dos registros $\rightarrow$ 99,8%
classificados como menor risco.

Regra 2 — Evento grave

STATUS ≥ 2 (60 dias ou mais de atraso)
pelo menos uma vez $\rightarrow$ 98,5%
classificados como menor risco.

Regra 3 — Escolhida

Combina gravidade e recorrência abaixo,
apresentando menor desbalanceamento.
 $\rightarrow$ 57,7% classificados como menor risco

TARGET = 1 (maior risco) quando:

- **recorrência** - STATUS = 1 (30–59 dias de atraso) mais que 2 vezes
- **gravidade** - STATUS ≥ 2 (60 dias ou mais de atraso) ao menor 1 vez
- **recorrência** - STATUS = 0 (1–29 dias de atraso) a partir de 6 vezes

3. Solução proposta

Transformar dados históricos em uma classificação de risco padronizável



Foram avaliados quatro modelos de classificação: Regressão Logística, Árvore de Decisão, Random Forest e Gradient Boosting.

O modelo é apresentado como ferramenta de apoio à decisão, e não como substituto da política de crédito.

4. Escolha do modelo

Random Forest apresentou o melhor equilíbrio geral

Modelo	Precision 1	Recall 1	F1 1	ROC-AUC 1	PR-AUC 1
Regressão Logística	0,59	0,54	0,57	0,54	0,60
Árvore de Decisão	0,59	0,75	0,66	0,55	0,60
Random Forest	0,73	0,72	0,72	0,74	0,77
Gradient Boosting	0,60	0,74	0,73	0,62	0,67

Decisão

Random Forest foi selecionado pelo melhor equilíbrio entre discriminação, precisão e desempenho sobre a classe de maior risco.

5. O que mais influencia o risco?

Importância das variáveis no Random Forest



Insight gerencial


As três principais variáveis — idade, renda e tempo de emprego — concentram aproximadamente 55% da importância atribuída pelo modelo.

O resultado sugere maior contribuição de características relacionadas ao perfil socioeconômico e à estabilidade do solicitante.

Importância de variável indica contribuição preditiva no modelo; não significa, isoladamente, causalidade.

6. Do modelo à decisão: o threshold

O ponto de corte traduz a probabilidade do modelo em uma regra operacional



Lógica gerencial: quando o custo de deixar passar um cliente de maior risco é superior ao custo de uma análise adicional, um threshold mais baixo pode ser adequado.

Pós Tech – Fiap 2026

GITHUB: <https://github.com/aalmeidaellen/postech-tech-challenge-fase2-grupoellen>

VÍDEO: https://drive.google.com/file/d/1mJN03B-PZMgLuPVpTfhf3BGdrs7gcFvz/view?usp=drive_link

APRESENTAÇÃO:

https://docs.google.com/presentation/d/17MHRfgp2IH3mUei9H3brGHqlzm90uBT4/edit?usp=drive_link&oid=101967518017721973819&rtpof=true&sd=true